CUPID MATCHMAKING

BILAN D’AVANCEMENT DU PROJET

ÉTAT ACTUEL
Machine Learning
entraîné et testé

Document de suivi partagé pour visualiser les tâches réalisées, les validations obtenues et les étapes restantes avant la livraison finale.

10/10	5	80/20	0
tests réussis	modèles comparés	train / test	échec de test

1. Compréhension du problème et exploration des données

☑ Définir le problème : prédire la compatibilité entre deux personnes.
☑ Identifier la variable cible compatible.
☑ Charger et examiner le dataset Cupid.
☑ Analyser les types de variables, valeurs manquantes et valeurs uniques.
☑ Réaliser l’analyse exploratoire des données (EDA).

2. Prétraitement et Feature Engineering

☑ Nettoyer les données et traiter les valeurs manquantes.
☑ Identifier les variables numériques et catégorielles.
☑ Encoder les variables catégorielles (One-Hot Encoding).
☑ Standardiser les variables numériques (StandardScaler).
☑ Créer des caractéristiques dérivées (Feature Engineering).
☑ Séparer les données en entraînement/test : 80 % / 20 %.
☑ Éviter la fuite de données pendant le prétraitement et la validation croisée.

3. Entraînement et optimisation des modèles

☑ Entraîner Logistic Regression, Decision Tree, Random Forest et XGBoost.
☑ Comparer les modèles sur le même découpage train/test.
☑ Optimiser XGBoost avec RandomizedSearchCV (6 configurations, 3 folds).
☑ Identifier les meilleurs hyperparamètres et sauvegarder le modèle retenu.

6. Application et livraison finale

☐ Vérifier l’intégration du modèle et du préprocesseur dans Flask.
☐ Tester une prédiction avec de nouvelles données.
☐ Vérifier les cas limites et la gestion des erreurs utilisateur.
☐ Finaliser et tester l’interface utilisateur.
☐ Mettre à jour le README et documenter l’exécution du projet.
☐ Rédiger le rapport final : données, méthode, résultats et limites.
☐ Préparer les diapositives et la démonstration.
☐ Répartir les parties de la soutenance entre les membres.
☐ Vérifier la version finale du dépôt GitHub.

7. Prochaines priorités recommandées

1	Revoir la Pull Request et intégrer les branches de l’équipe.
2	Tester l’application Flask avec les artefacts réellement générés.
3	Valider le parcours complet : saisie → prétraitement → prédiction → résultat.
4	Finaliser le rapport, le README et la présentation orale.

État général : la partie centrale de Machine Learning (prétraitement, entraînement, optimisation, évaluation et tests) est réalisée selon les éléments vérifiés dans le suivi. La revue/fusion de la Pull Request et la livraison applicative/documentaire restent à confirmer.

Légende : cases cochées = tâches réalisées selon les informations disponibles ; cases vides = tâches restantes ou dont la réalisation n’a pas encore été confirmée. Ce document est un état de suivi et doit être actualisé collectivement.